

Санкт-Петербургский политехнический университет  
Петра Великого

Институт прикладной математики и механики  
Кафедра «Прикладная математика»

Отчет по лабораторной работе № 1  
по эконометрике  
"Построение регрессионной модели, линейной по параметрам"

Выполнила студентка:  
Заболотских Екатерина  
группа: 3630102/70301

Проверил:  
к.ф.-м.н., доцент  
Иванков Алексей Александрович

Санкт-Петербург  
2021 г.

# Содержание

<b>1</b>	<b>Постановка задачи</b>	<b>2</b>
<b>2</b>	<b>Теория</b>	<b>2</b>
2.1	Нахождение точечной оценки $(\beta)$ . . . . .	2
2.1.1	Псевдообратная матрица . . . . .	2
2.2	SVD разложение . . . . .	3
2.2.1	Этап двухдиагонализации . . . . .	3
2.2.2	Этап диагонализации матрицы В . . . . .	4
2.3	Нахождение точечной оценки $\sigma$ . . . . .	4
2.4	Проверка однородности выборки . . . . .	5
<b>3</b>	<b>Реализация</b>	<b>5</b>
<b>4</b>	<b>Результаты</b>	<b>5</b>
<b>5</b>	<b>Выводы</b>	<b>6</b>

# 1 Постановка задачи

Имеется реализация случайного процесса. Задача состоит в построении регрессионной модели с разными аппроксимирующими полиномами. Нужно найти оценки параметров  $\beta$  с помощью минимизации квадратичной ошибки МНК, а также  $\sigma$ .

Оценить адекватность построенной регрессионной модели с помощью критерия однородности.

## 2 Теория

### 2.1 Нахождение точечной оценки ( $\beta$ )

Выберем базис в  $C^{(0)}[t_1, t_n]$  из полиномов и построим  $\hat{g}(t)$  как их композицию:

$$\hat{g}(t) = \hat{\beta}_0 t^0 + \hat{\beta}_1 t^1 + \dots + \hat{\beta}_k t^k \quad (1)$$

$$X(t) = z^T \beta + \xi(t) \quad (2)$$

, где

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \dots \\ \hat{\beta}_k \end{pmatrix}, t = \begin{pmatrix} t^0 \\ \dots \\ t^k \end{pmatrix}, z = \begin{pmatrix} 1 & 1 & \dots & 1 \\ t_1 & t_2 & \dots & t_n \\ \vdots & \vdots & \ddots & \vdots \\ t_1^k & t_2^k & \dots & t_n^k \end{pmatrix}, \xi(t) = \begin{pmatrix} \xi(t_1) \\ \dots \\ \xi(t_n) \end{pmatrix}$$

Чтобы найти точечные оценки  $\hat{\beta}$  минимизируем функционал:

$$S(\hat{\beta}) := \sum_{i=1}^n (X(t_i) - \hat{g}(t_i))^2 \quad (3)$$

Из условия существования глобального оптимума для выпуклой задачи:  $\frac{\partial S}{\partial \beta} = 0$ , сводим нахождение оценок к решению СЛАУ:

$$z * z^T * \hat{\beta} = z * X \quad (4)$$

#### 2.1.1 Псевдообратная матрица

**Теорема.** Матрица  $A^+ = V^T D^{-1} U$  является псевдообратной к матрице  $A$ . Док-во - просто рассмотреть  $AA^+$ . Тогда решение нормального уравнения сводится к

$$\hat{\beta} = (z * z^T)^+ * z * X$$

## 2.2 SVD разложение

Для того, чтобы решить СЛАУ, воспользуемся сингулярным разложением матрицы.

**Определение 2.1 (SVD-разложение)** Представление вещественной  $m \times n$  - матрицы  $\mathbf{A}$  в виде:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (5)$$

, где  $\mathbf{\Sigma}$  - диагональная  $m \times n$  - матрица с диагональю невозрастающих сингулярных чисел  $\sigma_1, \dots, \sigma_k$ , а  $\mathbf{U}$  и  $\mathbf{V}$  - ортогональные, соответственно  $m \times m$  и  $n \times n$  - матрицы, называется **сингулярным разложением** матрицы  $\mathbf{A}$ .

Поскольку фигурирующие в сингулярном разложении матрицы  $\mathbf{U}$  и  $\mathbf{V}$  - ортогональные, вполне естественно получить их в результате выполнения последовательностей простых ортогональных преобразований.

Весь процесс сингулярного разложения можно условно разбить на два этапа. Первый этап состоит в приведении исходной  $m \times n$  - матрицы  $\mathbf{A}$  к двухдиагональной форме, что реализуется с помощью преобразований Хаусхолдера. На втором этапе двухдиагональная матрица - итог первого этапа - приводится к диагональному виду, что достигается применением к ней QR-алгоритма на основе преобразований Гивенса.

### 2.2.1 Этап двухдигонализации

Данный этап состоит в том, что матрица  $\mathbf{A}$  умножается слева на матрицу Хаусхолдера  $\mathbf{P}_1$ , определяемую элементами  $a_{i1}$  первого столбца  $\mathbf{A}$  так, чтобы аннулировать все его элементы, находящиеся под диагональю.

Справа матрица  $\mathbf{P}_1\mathbf{A}$  умножается тоже на матрицу Хаусхолдера  $\mathbf{Q}_1$ , определяемую элементами  $\tilde{a}_{1j}$  первой строки матрицы  $\mathbf{P}_1\mathbf{A}$  так, чтобы аннулировать все элементы, стоящие правее элемента  $\tilde{a}_{12}$ . Следовательно результат этого шага - матрица:

$$\mathbf{A}_1 = \mathbf{P}_1\mathbf{A}\mathbf{Q}_1^T \quad (6)$$

, где

$$\begin{aligned} \mathbf{P}_1 &= \mathbf{E} - \mathbf{w}_1 * \mathbf{w}_1^T, \mathbf{w}_1 = \mu_1 * (a_{11} - p_1; a_{21}; \dots; a_{m1})^T \\ p_1 &= \text{sign}(-a_{11}) \sqrt{\sum_{i=1}^m a_{i1}^2}, \mu_1 = \frac{1}{\sqrt{2p_1^2 - 2 * p_1 * a_{11}}} \\ \mathbf{Q}_1 &= \mathbf{E} - \mathbf{z}_1 * \mathbf{z}_1^T, \mathbf{z}_1 = \nu_1 * (0, \tilde{a}_{12} - q_2; \tilde{a}_{13}; \dots; \tilde{a}_{1n})^T \\ q_2 &= \text{sign}(-\tilde{a}_{12}) \sqrt{\sum_{j=1}^m \tilde{a}_{1j}^2}, \nu_2 = \frac{1}{\sqrt{2q_2^2 - 2 * q_2 * \tilde{a}_{12}}} \end{aligned}$$

Нетрудно представить, что в результате конечного процесса таких преобразований данная  $m \times n$  - матрица  $\mathbf{A}$  будет ортогональна приведена к двухдиагональной форме.

В нашем случае матрица квадратная ( $m = n$ ), следовательно итог будет иметь вид:

$$\mathbf{B} = \begin{pmatrix} p_1 & q_2 & 0 & 0 & \dots & 0 & 0 \\ 0 & p_2 & q_3 & 0 & \dots & 0 & 0 \\ 0 & 0 & p_3 & q_4 & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & \dots & p_{n-1} & q_n \\ 0 & 0 & 0 & 0 & \dots & 0 & p_n \end{pmatrix} \quad (7)$$

$$\mathbf{A} = \mathbf{P}\mathbf{B}\mathbf{Q}^T$$

### 2.2.2 Этап диагонализации матрицы $B$

Полученную двухдиагональную матрицу  $B$  приведем к диагональному виду с помощью ортогональных преобразований вида:

$$B_{n+1} = SB_n T^T \quad (8)$$

, которые совершаются на основе плоских вращений Гивенса. При этом матрицы  $T$ , получаемые как произведения  $n - 1$  матриц вращений  $T_2, T_3, \dots, T_n$ , получаемых так, чтобы обеспечить сходимость последовательностей трехдиагональных матриц типа  $F = B^T B$  к диагональному виду в процессе QR-алгоритма.

На матрицы  $S$ , так же представляющие собой произведения  $n - 1$  матриц Гивенса  $S_2, S_3, \dots, S_n$ , возлагается обязанность поддерживать двухдиагональную структуру матрицам типа матриц  $B$  на каждом полном промежуточном шаге алгоритма. Итоговое разложение матрицы  $A$ :

$$A = PBQ^T = P(SDT^T)Q^T = UDV^T \quad (9)$$

## 2.3 Нахождение точечной оценки $\sigma$

Любая точечная оценка, вычисленная на основании опытных данных, является их функцией и поэтому сама должна представлять собой случайную величину с распределением, зависящим от распределения исходной случайной величины, в том числе от самого оцениваемого параметра и от числа опытов  $n$ .

К точечным оценкам предъявляется ряд требований, определяющих их пригодность для описания самих параметров.

1. Оценка называется состоятельной, если при увеличении числа наблюдений она приближается (сходится по вероятности) к значению оцениваемого параметра.
2. Оценка называется несмещенной, если ее математическое ожидание равно оцениваемому параметру.
3. Оценка называется эффективной, если ее дисперсия меньше дисперсии любой другой оценки данного параметра.

$$L(\xi_1, \xi_2, \dots, \xi_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(X(t_i) - g(t_i))^2}{2\sigma^2}} = \frac{1}{(\sqrt{2\pi\sigma^2})^{\frac{n}{2}}} e^{-\frac{\sum_{i=1}^n (X(t_i) - g(t_i))^2}{2\sigma^2}}$$

$$\ln(L) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (X(t_i) - g(t_i))^2 - n * \ln(\sigma) - \frac{n}{2} \ln(2\pi)$$

$$\left. \frac{d(\ln(L))}{d\sigma} \right|_{g=\hat{g}, \sigma=\hat{\sigma}} = \frac{1}{\hat{\sigma}^3} \sum_{i=1}^n (X_i - \hat{g}_i)^2 - \frac{n}{\hat{\sigma}} = 0$$

Откуда получаем:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{g})^2 = \frac{1}{n} \sum_{i=1}^n \hat{\xi}_t^2 \quad (10)$$

Но это смещенная оценка. Несмещенная выводится следующим образом:

$$M[S(\hat{\beta})] = M[(X - z^T \hat{\beta})^T (X - z^T \hat{\beta})] = \dots = n\sigma^2 - k\sigma^2 = (n - k)\sigma^2$$

$$\hat{\sigma}^2 = \frac{1}{n - k} \sum_{i=1}^n (X_i - \hat{g})^2 = \frac{1}{n - k} \sum_{i=1}^n \hat{\xi}_t^2 \quad (11)$$

## 2.4 Проверка однородности выборки

Критерий Манна — Уитни — статистический критерий, используемый для оценки различий между двумя независимыми выборками по уровню какого-либо признака, измеренного количественно. Позволяет выявлять различия в значении параметра между малыми выборками.

Этот метод определяет, достаточно ли мала зона перекрещивающихся значений между двумя рядами (ранжированным рядом значений параметра в первой выборке и таким же во второй выборке). Чем меньше значение критерия, тем вероятнее, что различия между значениями параметра в выборках достоверны.

## 3 Реализация

Моделируем случайный процесс, задаваемый в виде:  $X(t) = g(t) + \xi(t)$ , где  $g(t)$  - детерминированная величина, задаваемая полиномом 3-ей степени (с разными доминирующими слагаемыми);  $\xi(t)$  - случайная функция  $\sim N(0, \sigma)$ .

Задаем колличество интервалов разбиения. На каждом интервале разбиения находим параметры регрессионной модели  $\hat{\beta}$  и  $\hat{\sigma}$ . Находим  $\xi$  в каждой точке времени. Разделяем выборку на две части и оцениваем полученное  $P_{value}$ .

## 4 Результаты

Размер интервала разбиения для всех исследований брался равным 50 элементов. Случайный процесс строился мощностью в  $10^7$  элементов.

1. При моделировании случайного процесса  $g(t)$  было заданно с доминирующим слагаемым при 3-ей степени полинома:

$$g(t) = 8t^3 + 0.04t^2 + 0.07t + 0.06$$

Полученные результаты: ближе к началу временного интервала все модели дают хорошее приближение с точки зрения критерия однородности. Оценка  $\hat{\sigma}$  приближенно равна заданной.

Затем по критерию однородности не проходит модель с доминирующим свободным членом. Потом перестает проходить модель с доминирующим слагаемым при первой степени (линейная). Потом с доминирующей второй и третьей.

2.  $g(t)$  заданно с доминирующим слагаемым при 2-ей степени полинома:

$$g(t) = 0.04t^3 + 8t^2 + 0.07t + 0.06$$

Полученные результаты: результаты схожи с предыдущим пунктом.

3.  $g(t)$  заданно с доминирующим слагаемым при 1-ей степени полинома:

$$g(t) = 0.04t^3 + 0.07t^2 + 8t + 0.06$$

Полученные результаты: результаты схожи с предыдущим пунктом.

4.  $g(t)$  заданно с доминирующим слагаемым при 0-ей степени полинома:

$$g(t) = 0.04t^3 + 0.07t^2 + 0.06t + 8$$

Полученные результаты: результаты схожи с предыдущим пунктом. Модель с доминирующим свободным членом работает лишь в окрестности 0.

## 5 Выводы

Регрессионная модель, линейная по параметрам, адекватна лишь в окрестности нуля. Чем дальше, тем хуже аппроксимация тренда. Модели с доминирующими свободным членом и коэффициентом при первой степени полинома раньше дают большую погрешность приближения, чем модели с доминирующими коэффициентами при 2 и 3 степенях полинома.

Точечная оценка  $\sigma$  растёт во времени.